



Zadatak za vježbu 1.

18. svibnja 2026.

Cilj zadaće

Implementirati deterministički proračun elastične progibne linije i kritičnih odziva slobodnooslonjene armiranobetonske grede, te provesti **Monte Carlo** (MC) analizu pouzdanosti za tri granična stanja uzimajući u obzir geometrijsku i materijalnu varijabilnost kao i varijabilnost opterećenja. Prikazati rezultate putem detaljnih vizualizacija.


Sadržaj

1.	Opis konstrukcijskog problema	2
2.	Slučajne varijable i statistički parametri	4
3.	Granična stanja	6
4.	Monte Carlo metoda – algoritam	8
5.	Zahtijevane vizualizacije	10
6.	Deterministički rezultati – referentne vrijednosti	12

1. Opis konstrukcijskog problema

Razmatra se **slobodnooslonjena armiranobetonska greda** pravokutnog poprečnog presjeka, opterećena **jednolikim kontinuiranim opterećenjem** q [kN/m] po cijelom rasponu L . Greda je simetrična oko sredine raspona; oslonci su zglobni (bez momenta).

1.1. Geometrija i materijal



Slika 1: Shematski prikaz slobodnooslonjene grede s ukupnim opterećenjem (lijevo) i pravokutnog poprečnog presjeka s karakterističnim veličinama (desno).

1.2. Deterministički proračun

1.2.1. Moment inercije i moment otpora

Za pravokutni poprečni presjek širine b i visine h vrijedi:

$$I = \frac{b h^3}{12}, \quad (1.1)$$

$$W = \frac{b h^2}{6}. \quad (1.2)$$

1.2.2. Elastična progibna linija

Diferencijalna jednačba elastične linije za gredi s konstantnom krutosti EI i ukupnim opterećenjem q daje progib u točki x :

$$\delta(x) = \frac{q x}{24 E I} \left(L^3 - 2 L x^2 + x^3 \right), \quad 0 \leq x \leq L. \quad (1.3)$$

1.2.3. Maksimalni progib

Maksimalni progib u sredini raspona ($x = L/2$) dobiva se iz eq. (1.3):

$$\delta_{\max} = \frac{5 q L^4}{384 E I}. \quad (1.4)$$

1.2.4. Maksimalna rotacija uz oslonce

Kut zakreta (rotacija) poprečnog presjeka uz oslonce ($x = 0$ ili $x = L$) jednak je:

$$\theta_{\max} = \left. \frac{d\delta}{dx} \right|_{x=0} = \frac{q L^3}{24 E I}. \quad (1.5)$$

1.2.5. Maksimalni moment savijanja i normalno naprezanje

Moment savijanja ima paraboličan raspored s maksimumom u sredini:

$$M_{\max} = \frac{q L^2}{8}. \quad (1.6)$$

Maksimalno normalno naprezanje (u rubu presjeka u sredini raspona) jednako je:

$$\sigma_{\max} = \frac{M_{\max}}{W} = \frac{q L^2}{8} \cdot \frac{6}{b h^2} = \frac{3 q L^2}{4 b h^2}. \quad (1.7)$$

Napomena – pozitivne konvencije

Progib $\delta(x)$ definiran je prema dolje kao pozitivan. Rotacija θ izražena je u radijanima [rad]. Normalno naprezanje σ uzima se kao tlačno (pozitivno) za rubni sloj koji odgovara savojnom momentu.

2. Slučajne varijable i statistički parametri

2.1. Odabir tipa razdiobe

Sve ulazne veličine modeliraju se kao **log-normalno distribuirane** slučajne varijable, što je standardni pristup u inženjerskoj pouzdanosti:

- log-normalna razdioba isključuje negativne vrijednosti (fizički ispravno za geometriju, materijal i opterećenje);
- prikladna je za veličine čiji je koeficijent varijacije $\text{CoV} \lesssim 0,30$;
- suma logaritama log-normalnih varijabli je normalno distribuirana (olakšava teorijsku analizu).

2.2. Parametrizacija log-normalne razdiobe

Ako je slučajna varijabla $X \sim \mathcal{LN}(\mu_{\ln}, \sigma_{\ln})$, parametri su određeni iz zadane srednje vrijednosti μ_X i koeficijenta varijacije $\text{CoV}_X = \sigma_X / \mu_X$:

$$\sigma_{\ln} = \sqrt{\ln(1 + \text{CoV}_X^2)}, \quad (2.1)$$

$$\mu_{\ln} = \ln(\mu_X) - \frac{\sigma_{\ln}^2}{2}. \quad (2.2)$$

Uzorkovanje log-normalnih uzoraka u Pythonu (NumPy):

Listing 1: Uzorkovanje log-normalne razdiobe u NumPy

```
1 def ln_params(mu, cov):
2     """Parametri log-normalne razdiobe iz (mu, CoV)."""
3     sigma_ln = np.sqrt(np.log(1.0 + cov**2))
4     mu_ln = np.log(mu) - 0.5 * sigma_ln**2
5     return mu_ln, sigma_ln
6
7 def sample_lognormal(mu, cov, n, rng):
8     mu_ln, sig_ln = ln_params(mu, cov)
9     return rng.lognormal(mu_ln, sig_ln, n)
```

2.3. Definicija slučajnih varijabli

Table 1 prikazuje svih šest slučajnih varijabli s njihovim statističkim parametrima. Varijable se tretiraju kao **međusobno nezavisne** (bez korelacije).

Tablica 1: Slučajne varijable – srednje vrijednosti, koeficijenti varijacije i fizikalna interpretacija.

Simbol	Veličina	Jed.	μ	CoV	Obrazloženje varijabilnosti
L	Raspon grede	m	7,00	0,01	Geometrijska tolerancija; $\sigma_L \approx 70$ mm
b	Širina presjeka	m	0,25	0,04	Izvedba oplata; $\sigma_b \approx 10$ mm
h	Visina presjeka	m	0,40	0,04	Izvedba oplata; $\sigma_h \approx 16$ mm
E	Modul elastičnosti	GPa	30,0	0,12	Varijabilnost čvrstoće betona; inherentna nesigurnost
q	Ukupno opterećenje	kN/m	22,0	0,20	Stalno + korisno opterećenje; $\sigma_q \approx 4.4$ kN/m
f_{ck}	Čvrstoća betona	MPa	30,0	0,15	Tlačna čvrstoća (C30/37); $\sigma_f \approx 4.5$ MPa

Napomena – realne vrijednosti CoV

Navedene vrijednosti koeficijenata varijacije temelje se na preporukama *JCSS Probabilistic Model Code* [3] i Eurokodu 1990 [4]:

- geometrijski parametri (b, h): CoV = 0,03–0,05;
- modul elastičnosti betona: CoV = 0,10–0,15;
- stalno opterećenje: CoV $\approx$ 0,10; korisno opterećenje: CoV = 0,20–0,30;
- čvrstoća betona (f_{ck}): CoV = 0,12–0,18.

U ovom zadatku q objedinjuje stalno i korisno opterećenje, pa je usvojen umjereni CoV = 0,20.

3. Granična stanja

Granično stanje definira se funkcijom pouzdanosti (eng. *limit state function*):

$$g(\mathbf{X}) = R(\mathbf{X}) - S(\mathbf{X}), \quad (3.1)$$

gdje je R otpornost (kapacitet), S zahtjev (odziv). **Otkazivanje** nastupa kada $g(\mathbf{X}) < 0$.

3.1. GS-1 – Ograničenje progiba

Granično stanje upotrebljivosti prema EN 1990 ograničava maksimalni progib na $L/250$. Funkcija pouzdanosti:

$$g_1(\mathbf{X}) = \frac{L}{250} - \delta_{\max}(q, L, E, b, h) = \frac{L}{250} - \frac{5 q L^4}{384 E I(b, h)}. \quad (3.2)$$

Komentar

Limitna vrijednost $L/250$ sama je funkcija slučajne varijable L , pa se raspoređuje Monte Carlo uzorkom zajedno s ostalim varijablama. Stoga gornja i donja strana nejednakosti imaju *iste* statističke karakteristike varijabilnosti raspona.

3.2. GS-2 – Ograničenje rotacije uz oslonce

Prekomjerna rotacija uz oslonce može uzrokovati oštećenja na pričvršćenim elementima (npr. pregradni zidovi, spojevi na osloncima). Granica je fiksna deterministička vrijednost $\theta_{\lim}$:

$$g_2(\mathbf{X}) = \theta_{\lim} - \theta_{\max}(q, L, E, b, h) = \theta_{\lim} - \frac{q L^3}{24 E I(b, h)}, \quad (3.3)$$

s usvojenom granicom $\theta_{\lim} = 0.012 \text{ rad} \approx 12.0 \text{ mrad}$.

3.3. GS-3 – Ograničenje normalnog naprezanja

Maksimalno normalno naprezanje od savijanja ne smije prekoračiti karakterističnu čvrstoću betona f_{ck} :

$$g_3(\mathbf{X}) = f_{ck} - \sigma_{\max}(q, L, b, h) = f_{ck} - \frac{3 q L^2}{4 b h^2}. \quad (3.4)$$



Napomena – GS-3

Varijabla f_{ck} je *slučajna* (log-normalna), što stvara interakciju između opterećenja q (varijabilnost S) i čvrstoće f_{ck} (varijabilnost R) — karakterističan slučaj R - S modela pouzdanosti. U realnom dimenzioniranju koristio bi se projektni parametar $f_{cd} = f_{ck}/\gamma_c$, ali ovdje namjerno koristimo f_{ck} radi pedagoškog prikaza varijabilnosti otpornosti.

3.4. Sažetak graničnih stanja

Tablica 2: Pregled graničnih stanja, odgovarajućih funkcija g_i i limitnih vrijednosti.

Oznaka	Fizikalni smisao	Limitna vrijednost	Odzivna veličina
GS-1	Progib	$\delta_{\lim} = L/250$	$\delta_{\max}$
GS-2	Rotacija	$\theta_{\lim} = 12.0 \text{ mrad}$	$\theta_{\max}$
GS-3	Naprezanje	$\sigma_{\lim} = f_{ck}$	$\sigma_{\max}$

4. Monte Carlo metoda – algoritam

4.1. Osnove metode

Monte Carlo (MC) metoda numerički aproksimira integral koji daje vjerojatnost otkazivanja:

$$P_f = P[g(\mathbf{X}) < 0] = \int_{g(\mathbf{x}) < 0} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}, \quad (4.1)$$

gdje je $f_{\mathbf{X}}(\mathbf{x})$ zajednička gustoća vjerojatnosti svih slučajnih varijabli. Procjena se temelji na uzorkovanju:

$$\hat{P}_f = \frac{1}{N} \sum_{k=1}^N \mathbf{1}[g(\mathbf{x}^{(k)}) < 0], \quad (4.2)$$

gdje je $\mathbf{1}[\cdot]$ indikatorska funkcija (vrijednost 1 ako je uvjet ispunjen, inače 0), a $\mathbf{x}^{(k)}$ je k -ti uzorak vektora ulaznih varijabli.

4.2. Statistika procjenitelja

MC procjenitelj (4.2) je **nepristran**, s varijancom:

$$\text{Var}(\hat{P}_f) = \frac{P_f(1 - P_f)}{N}. \quad (4.3)$$

Koeficijent varijacije MC procjenitelja:

$$\text{CoV}_{\hat{P}_f} = \sqrt{\frac{1 - P_f}{N \cdot P_f}} \approx \frac{1}{\sqrt{N \cdot P_f}} \quad (P_f \ll 1). \quad (4.4)$$

95% interval pouzdanosti za $\hat{P}_f$:

$$\hat{P}_f \pm 1,96 \sqrt{\frac{\hat{P}_f(1 - \hat{P}_f)}{N}}. \quad (4.5)$$

Minimalni broj simulacija

Iz (4.4) slijedi: za ciljnu točnost $\text{CoV}_{\hat{P}_f} \leq 10\%$ i procijenjenu vjerojatnost P_f , potrebno je najmanje

$$N_{\min} \approx \frac{100}{P_f} \quad (4.6)$$

simulacija. Primjer: $P_f \approx 10^{-2}$ zahtijeva $N \gtrsim 10\,000$.

4.3. Algoritam implementacije

Korak 1. Definirati statističke parametre svih slučajnih varijabli (srednje vrijednosti i CoV prema table 1).

Korak 2. Izračunati parametre log-normalne razdiobe prema jednadžbama (2.1)–(2.2).

Korak 3. Generirati N neovisnih uzoraka svakog vektora $\mathbf{X} = (L, b, h, E, q, f_{ck})$ iz odgovarajućih log-normalnih razdioba (preporuča se $N = 100\,000$ simulacija).

Korak 4. Izračunati odzive za svaki uzorak: $I^{(k)}, \delta_{\max}^{(k)}, \theta_{\max}^{(k)}, \sigma_{\max}^{(k)}$.

Korak 5. Evaluirati funkcije graničnih stanja $g_1^{(k)}, g_2^{(k)}, g_3^{(k)}$ prema jednadžbama (3.2)–(3.4).

Korak 6. Odrediti događaje otkazivanja: $F_i^{(k)} = 1[g_i^{(k)} < 0]$ za svaki k i svako granično stanje $i \in \{1, 2, 3\}$.

Korak 7. Izračunati procjene vjerojatnosti otkazivanja prema (4.2).

Korak 8. Vizualizirati rezultate (detalji u section 5).

Listing 2: Osnovna MC petlja – pseudokod u Pythonu

```
1 import numpy as np
2 rng = np.random.default_rng(2024) # reproducibilnost
3 N = 100_000
4
5 # Korak 3: generiranje uzoraka
6 L_s = sample_lognormal(L_mu, CoV_L, N, rng)
7 b_s = sample_lognormal(b_mu, CoV_b, N, rng)
8 h_s = sample_lognormal(h_mu, CoV_h, N, rng)
9 E_s = sample_lognormal(E_mu, CoV_E, N, rng)
10 q_s = sample_lognormal(q_mu, CoV_q, N, rng)
11 fc_s = sample_lognormal(fc_mu, CoV_fc, N, rng)
12
13 # Korak 4: odzivi
14 I_s = b_s * h_s**3 / 12
15 delta_s = 5 * q_s * L_s**4 / (384 * E_s * I_s)
16 theta_s = q_s * L_s**3 / (24 * E_s * I_s)
17 sigma_s = 3 * q_s * L_s**2 / (4 * b_s * h_s**2)
18
19 # Korak 5--6: GS i otkazivanje
20 g1 = L_s / 250.0 - delta_s
21 g2 = theta_lim - theta_s
22 g3 = fc_s - sigma_s
23
24 fail1 = g1 < 0
25 fail2 = g2 < 0
26 fail3 = g3 < 0
27
28 # Korak 7: procjene
29 pf1 = np.mean(fail1)
30 pf2 = np.mean(fail2)
31 pf3 = np.mean(fail3)
```

5. Zahtijevane vizualizacije

Sve slike trebaju biti **jasno naslovljene**, s opisanim osima, legendom i jedinicom na svakoj osi. Preporuča se DPI = 300 pri pohrani.

5.1. Slika 1 – Deterministički model

- **Lijevi panel:** Elastična progibna linija $\delta(x)$ [jednadžba (1.3)] ucrtana s negativnim predznakom (prema dolje), s horizontalnom isprekidanom linijom granice $L/250$. Kotirati $\delta_{\max}$ strelicom.
- **Desni panel:** Shematski prikaz poprečnog presjeka s dimenzijama b i h , momentom inercije I i modulom E .

5.2. Slika 2 – Scatter plotovi za tri granična stanja

Prikazati **tri bočno smještена** (1×3) scatter diagrama (podskup od $\sim 8\,000$ nasumično odabranih uzoraka radi preglednosti):

- a) **GS-1:** os $x = \delta_{\max}$ [mm], os $y = L/250$ [mm]. Ucertati dijagonalnu granicu $\delta_{\max} = L/250$. Uzorci ispod dijagonale (sigurno) u zelenoj boji, iznad (otkazivanje) u crvenoj.
- b) **GS-2:** os $x = \theta_{\max}$ [mrad], os $y = q$ [kN/m]. Ucertati vertikalnu liniju $\theta_{\max} = \theta_{\lim}$.
- c) **GS-3:** os $x = \sigma_{\max}$ [MPa], os $y = f_{ck}$ [MPa]. Ucertati dijagonalnu granicu $\sigma_{\max} = f_{ck}$.

U naslovu svakog panela ispisati procijenjenu $\hat{P}_f$.

5.3. Slika 3 – Histogrami slučajnih varijabli

Šest panela (2×3), za svaku varijablu:

- histogram uzorkovanih vrijednosti (gustoća vjerojatnosti);
- preklapljena teorijska PDF log-normalne razdiobe;
- vertikalne linije za srednju vrijednost μ i uzoračku sredinu $\bar{x}$.

5.4. Slika 4 – Konvergencija $\hat{P}_f$

Tri panela (1×3), jedan za svako GS:

- kumulativna procjena $\hat{P}_f(n) = \frac{1}{n} \sum_{k=1}^n F_i^{(k)}$ u ovisnosti o n na **logaritamskoj osi** x ;
- sjenčani 95% interval pouzdanosti prema (4.5);
- horizontalna isprekidana linija na konačnoj vrijednosti $\hat{P}_f(N)$;
- vertikalne dotted linije na $n \in \{100, 1\,000, 10\,000, 100\,000\}$.

5.5. Slika 5 – Razdiobe odzivnih veličina

Tri panela (1×3) s histogramima odziva ($\delta_{\max}$, $\theta_{\max}$, $\sigma_{\max}$):

- za GS-3 preklopiti i histogram f_{ck} (slučajna otpornost!);



Sveučilište Josipa Jurja Strossmayera u Osijeku
Građevinski i arhitektonski fakultet Osijek
Josip Juraj Strossmayer University of Osijek
Faculty of Civil Engineering and Architecture Osijek



Računalno programiranje u građevinarstvu (RPuG) **Izv. prof. dr. sc. Marin Grubišić**

- za GS-1 i GS-2 prikazati vertikalnu liniju limitne vrijednosti;
- za svaki panel nijansirati zonu otkazivanja ($g < 0$).

6. Deterministički rezultati – referentne vrijednosti

Tablica 3: Deterministički rezultati za srednje vrijednosti svih parametara.

Veličina	Formula	Vrijednost	Granica	Omjer
Moment inercije I	$bh^3/12$	1333 cm ⁴	—	—
Maks. moment $M_{\max}$	$qL^2/8$	134.75 kNm	—	—
Progib $\delta_{\max}$	Jed. (1.4)	17.19 mm	$L/250$ 28.00 mm	= 0,614
Rotacija $\theta_{\max}$	Jed. (1.5)	7.86 mrad	12.00 mrad	0,655
Naprezanje $\sigma_{\max}$	Jed. (1.7)	20.21 MPa	$f_{ck} = 30.00$ MPa	0,674

Interpretacija omjera

Deterministički omjer $\delta_{\max}/(L/250) \approx 0,61 < 1,0$ znači da greda zadovoljava sva tri granična stanja sa sigurnosnom rezervom od 33%–39%. Unatoč tome, Monte Carlo analiza pokazuje *nenemariv* $\hat{P}_f$ zbog varijabilnosti parametara — što je ključna poruka ovog zadatka.

Literatura

- [1] Haldar, A., Mahadevan, S. *Probability, Reliability, and Statistical Methods in Engineering Design*. John Wiley & Sons, New York, 2000.
- [2] Melchers, R. E. *Structural Reliability Analysis and Prediction*. John Wiley & Sons, Chichester, 1999.
- [3] JCSS – Joint Committee on Structural Safety. *Probabilistic Model Code*. Dostupno na: <https://www.jcss-lc.org>, 2001.
- [4] HRN EN 1990:2011. *Eurocode – Osnove projektiranja konstrukcija*. HZN, Zagreb, 2011.
- [5] HRN EN 1992-1-1:2013. *Eurocode 2 – Projektiranje betonskih konstrukcija*. HZN, Zagreb, 2013.
- [6] McKay, M. D., Beckman, R. J., Conover, W. J. A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, **21**(2):239–245, 1979.